15篇论文学习报告 | 2026-10-25

工业缺陷检测：从读懂论文到设计自己的实验

研究主线：监督式工业表面缺陷框检测、模型压缩与边缘部署。结合你此前的RK3568工业视觉背景，本报告把“能否保住微小缺陷、是否真的在板上更快、面对成像变化是否可靠”作为贯穿问题。若最终课题转向无监督异常检测，这批文献只能提供部分压缩与部署方法。



图1 | 训练、压缩与部署的分工。AI辅助生成的概念示意，已核查标签；板卡外观不是具体实验装置证据。

先记住三个判断

剪枝改变结构，蒸馏改善学习，量化改变数值表示；最终效果要在同一模型、测试集与硬件上配对验证。低参数、低FLOPs、高GPU FPS，都不能独立证明RK3568上的收益。

阅读方式：先读“导航”和“共同基础”，再按论文页选读；每篇都有方法解释、配对结果、局限、学习点与下一步实验。HTML支持搜索、主题筛选、阅读勾选与自测答案展开；PDF适合顺序学习和批注。

证据标记：表中数值为作者报告；“本报告计算”明确写公式；“建议/解释”是阅读判断，未在你的开发板执行。所有原文页码均指本地PDF阅读器页序，不是期刊印刷页。

导航 | 先建知识地图，再记缩写

15篇分别负责教你什么

任务	对应论文	最值得带走的东西
剪掉真实结构	P01、P04、P15	训练预算、依赖关系、公平比较剪枝准则
剪后恢复能力	P02、P09、P10、P11	教师/学生设计，拆开压缩损失与KD收益
理解蒸馏机制	P05、P13	前背景、局部/全局、纹理与输出监督
理解量化代价	P06、P12	校准、重构误差、位宽与精度/延迟权衡
真实设备与系统	P03、P07、P08、P10、P14	后端执行、资源、计时边界、证据缺口

建议阅读顺序（是本报告的学习安排）

第一轮：P01→P02→P03，建立剪枝、恢复、部署的主线。第二轮：P04→P05→P11→P12，补依赖处理、蒸馏与量化。第三轮：P10→P07，核查最接近RK3568的工程案例。最后按需读P08、P09、P13、P14、P15，不必先背所有模块名。

你的方向可以从这批文献得到什么

可直接借用的是实验框架：固定检测任务，构建较强教师，选可导出的小学生，做结构剪枝和KD，再量化上板。更值得研究的是交互：哪些小缺陷在压缩与INT8后首先丢失？哪些理论更省的结构实际更慢？光照或批次变化是否放大这种损失？

选题边界

本报告基于用户提供的15篇，不是穷尽检索。已有剪枝+KD、Rockchip基准和多准则比较研究，不能把“把这些步骤串起来”直接宣称为全新贡献；正式立题前仍需面向具体假设补查近期文献。

避免把不同问题的数字混在一起

共同基础一：先读懂指标，再看谁更好

概念	直白解释	读论文时必须问
框检测 / 分类 / 分割	找位置和类别 / 只判类别 / 逐像素标注	本文结果到底属于哪一种任务?
Precision / Recall	报出的有多少真缺陷 / 真缺陷检出多少	阈值相同吗？正常件误报与漏检分别多少?
AP / mAP	PR曲线下的面积 / 类别AP平均	IoU阈值、插值与类别集合是否相同?
mAP50 / 50:95	宽松匹配 / 跨多个更严格IoU阈值平均	是否只是能框到，还是位置也准确?
参数 / FLOPs / MACs	模型规模 / 计算计数 / 乘加计数	MAC算一次还是两次？输入大小多少?
文件大小 / 峰值RAM	磁盘工件 / 运行时最高内存	格式、位宽、中间特征与缓存是否计入?
延迟 / 吞吐	一帧等待多久 / 单位时间处理多少帧	batch、流水线、热身、采集与NMS包含哪些?
W / mJ每帧	每秒用能速率 / 完成一帧消耗	平均还是最大？测整板还是芯片?

例：mAP从70.0%到71.0%，是提高1.0个百分点；相对提高约1.43%。两者不能混写。“mAP50提高而50:95降低”不矛盾：更多框达到宽松IoU，但精确定位可能变差（P10）。

串行、batch=1且计时边界一致时，FPS约等于1000/延迟ms；多线程流水线或batch吞吐不能这样直接换算。功率P与时间t对应同一范围时，E=P×t；用最大功率乘平均延迟只能给特定估计，不能冒充实测平均能量。

小缺陷的特别风险

整体mAP很高，也可能漏掉少数关键裂纹。至少同时查看按类别、缺陷像素尺寸、低对比与正常件分组的结果。框IoU对极小目标的几像素偏移非常敏感。

方法图解 | P01、P02、P04、P09、P11、P15

共同基础二：剪枝不是简单删掉一些数字

非结构化剪枝把分散权重置零；若后端仍按稠密矩阵执行，文件中的零并不会自动变成速度。结构化剪枝实际删除通道、过滤器或层，同时减少相邻输入维度，更容易得到普通推理后端可执行的小网络；实际提速仍要测。

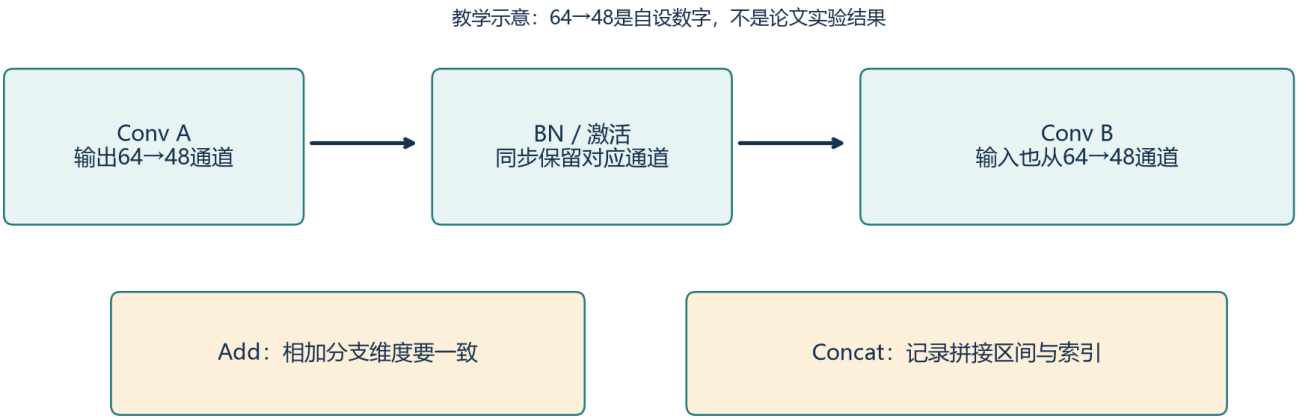


图2 | 依赖关系的教学示意，依据DepGraph原理绘制。图中64→48是自设例子，非论文实验数据。

重要性线索	代表文献	它只是一个什么代理
BN缩放系数 |γ|	P01、P02、P15	通道被缩放的程度，不等于缺陷因果重要性
过滤器L1 / 通道L2范数	P11 / P09	权重幅值，小幅值也可能承载少见缺陷
层自适应 / 组依赖	P10 / P04	分配稀疏预算或维护耦合一致性
BN+特征秩	P08	结合权重与响应冗余，仍须验证稳定性

通用步骤的教学抽象（不是某篇论文原算法逐字翻译）

输入：已训练模型、训练/验证集、压缩目标、受保护输出层。①建立依赖组；②计算重要性并选候选组；③删结构且同步改索引；④前向与导出检查；⑤相同预算下微调或KD；⑥验证精度并测目标板延迟；⑦保留非支配候选。输出：可执行学生及其完整评测记录。

复杂度直觉：普通卷积参数约为$K^2 \times Cin \times Cout$，计算还乘H×W；删某层输出通道也会影响下一层输入。扩大P2等高分辨率分支则会增加激活与带宽成本。不能只看一个层的参数。

教师、学生、监督信号与推理成本

共同基础三：蒸馏到底在教什么

监督层次	学生学什么	代表方法 / 风险
中间特征	哪些纹理、边缘与语义值得表示	Mimic / 对齐后MSE可能被背景主导
前景与背景注意力	哪里重要、哪些通道重要	FGD / 框内不全是缺陷，背景也有价值
全局关系	各位置或通道如何相互关联	FGD、DCG / 更多训练成本与适配
类别输出	教师对各候选类别的判断	软标签 / Sigmoid与Softmax语义有别
框定位输出	框在哪里、尺寸如何	P02、P11 / 教师错误会传给学生

便于理解的总式：L总 = L真实标注 + αL特征 + βL类别 + γL定位。各篇具体损失不同，这只是教学框架；α、β、γ不能不经验证从一篇复制到另一篇。教师与学生通道不同时，可在训练中使用对齐映射，但须核查它是否被错误留进最终推理图。

为什么只部署学生也能受益

学生在训练时获得更丰富的目标与优化方向，推理时仍只算学生本身。因此“同一个学生加KD”通常体现为精度提高，不体现为参数再少或推理更快。P11、P13最能直接看出这一点。蒸馏训练会额外运行教师，训练成本必须另报。

最小公平对照

固定学生结构、初始化来源、数据增强、训练轮数、教师检查点与评估器。比较普通微调、普通特征KD、任务相关KD；若KD用了更久训练，还要加同等时长的普通微调。报告至少多个独立种子的均值与离散程度，不能把不同IoU阈值当作重复实验。

与小缺陷的联系

教师总体mAP更高，不保证它对少见小裂纹更好。先看教师在目标子集的能力，再研究是否蒸馏；不要让学生稳定地复制教师的漏检。

P06提供原理，P03/P07/P08/P12提供应用与边界

共同基础四：PTQ、QAT与编译链路

量化把连续浮点数映射到有限整数格点。教学表达：q=clip(round(x/s)+z)，还原值约为s(q−z)，其中s控制刻度、z为零点。例：刻度0.1、零点0时，0.26可近似成0.3；这个数只是说明舍入，非任何论文结果。权重、激活都可能量化，位宽与每层混合精度要分开记录。

方式	训练/优化含义	对这批文献的用法
PTQ	先有浮点模型，用校准统计定刻度；部分算法还优化重构	RKNN/TensorRT案例；AdaRound是自适应舍入PTQ
QAT	训练时模拟量化误差以调整权重	不能仅因出现INT8就认定做了QAT
编译 / 运行	图融合、算子映射、内存与调度	相同INT8在不同后端可能混用精度或回退CPU

数据必须有明确职责

训练集拟合模型；验证集选择剪枝率与超参数；校准集估计量化范围，通常无需标签；最终测试集只用于最后评估。可以从训练分布独立抽取校准子集，但应记录来源，避免依据最终测试表现反复调校准而产生选择偏差。成像条件和缺陷尺寸都要覆盖。

上板前后逐站检查

PyTorch浮点→ONNX→RKNN编译工件→板端输出，每站用相同图像核查数值与框。重点检查RGB/BGR、resize/letterbox、归一化是否重复、输出解码与NMS。先排除预后处理不一致，再判断是否为量化误差。最后读取编译/运行日志确认实际执行方式。

为什么INT8可能更慢

低位宽降低算术与存储负担，但算子回退、反复类型转换、激活读写与小算子调度可能抵消优势。P08提供现象证据；具体因果需要目标后端日志和性能剖析。

本报告自定义标签，不是期刊评级或论文质量总分

15篇的证据边界：哪些真的回答了部署问题

论文	场景 / 主要贡献	真实边缘运行	最终配置精度与速度闭环
P01	工业 / 剪枝	否，GPU	无NPU闭环
P02	工业 / 剪枝+KD	AGX Xavier	有最终学生；缺原大模型同板配对
P03	通用 / RK基准	多Rockchip SoC	缺逐板最终INT8精度配对
P04	通用 / 依赖剪枝	非本任务证据	无工业NPU闭环
P05	通用 / 检测KD	否	无工业NPU闭环
P06	分类/分割 / PTQ	非本任务证据	无工业框检测闭环
P07	工业 / RKNN INT8	RK3568	跨平台对照；AP定义异常
P08	工业 / 组合压缩	AGX Orin	同板速度强；缺最终引擎mAP
P09	工业 / 迁移+剪枝+KD	否，GPU	无板端闭环
P10	工业 / 剪枝+KD	RK3568	小样本计数；缺板端延迟
P11	工业 / 剪枝+KD	否，GPU	无板端闭环
P12	工业 / TensorRT量化	桌面RTX4070	同机精度-延迟，非边缘板
P13	工业 / RT-DETR KD	否，GPU	无板端闭环
P14	工业 / 原生架构	Xavier NX	同板多资源；无压缩前后因果
P15	工业 / 剪枝准则	否，GPU	无板端闭环

主工业压缩案例是P01/P02/P07/P08/P09/P10/P11/P12/P13/P15；P03/P04/P05/P06是通用方法或部署参考；P14是原生架构与资源基线。区分后再比较，不能把这15篇当成同质实验样本做总体mAP/FPS排名。

“证据不闭环”指缺少回答特定问题的必要观测，不等于方法没有价值。我们的严格问题是：相同任务与测试集、相同板与计时范围下，最终可执行模型是否既保精度又改善延迟/资源？这批论文没有完整回答你的RK3568场景。

2024 · ISIJ International | 剪枝 | 精读

P01 | RDDPA：把剪枝变成可训练的小网络

一句话抓住贡献

真正值得学的是：先得到合理的小结构，再给它合适的训练预算，而非只寻找一个神奇的剪枝分数。

写了什么：问题与方法

面向钢材缺陷，减少模型计算与存储，同时简化常见的稀疏训练、剪枝、微调三阶段流程。它是以Tiny-Darknet和中心点预测为基础的检测框架，并非YOLO改版。

以ImageNet预训练骨干的BN缩放系数绝对值衡量通道重要性，按阈值删通道；同步调整检测颈部的连接维度。这里的“从头训练”不等于完全不利用ImageNet信息：选结构仍使用了预训练权重。

把保留通道数规整为16的倍数，再训练剪后检测器；用随剪枝率调整学习率、衰减节点和训练轮数的策略，缓解小模型欠拟合或收敛不足。16倍数是本文设计，不能直接视作RK3568最优值。

结果怎样读

NEU-DET，1800张、6类；70%训练/30%评估；输入384×384；同机对照为GTX 960M。原文mAP的IoU口径未明确核实，保留其名称。

同机配置	参数 / FLOPs	mAP / FPS
未剪枝	6.7M / 6.2G	79.9% / 21.6
3.0×配置	2.2M / 4.4G	79.9% / 27.0
10.8×配置	0.6M / 1.8G	79.2% / 40.1

在这组条件下，高压缩模型以0.7个百分点mAP换得约1.86倍吞吐；这既不是10.8倍实测加速，也不是RK3568结果。Table 5中同一高压缩结构加入训练策略后mAP由76.8%到79.2%，说明训练方案本身贡献不小。

我能学到什么，对我的方向有什么用

学会区分“结构选择”和“权重恢复”；剪后精度差时，先查训练预算是否足够，再判定剪枝准则无效。 可做的小实验：在同一个YOLO学生上比较普通微调与延长训练，并额外记录训练耗时；用实际板端延迟筛选通道对齐方式。

保留的限制与原文入口

单一小数据集、缺少真实NPU和量化闭环；不同压缩配置训练预算变化，无法把全部改善归因于通道分数。摘要中的103.7 FPS来自Titan X。

读图路线：先看Fig.3理解删的是通道，再看Table 2的规模、内存与FPS是否同步变化，最后用Table 5检查训练策略的独立贡献。

原文定位：§3.2、§4.1–4.5；PDF pp.4–9；Table 1、2、3、5。

2024 · Electronics | 剪枝+蒸馏 | 精读

P02 | 微小工件缺陷：剪枝后用蒸馏救回精度

一句话抓住贡献

这是最直观的“强模型→删冗余→蒸馏恢复→嵌入式运行”学习案例。

写了什么：问题与方法

对偏心锥形工件的凹坑、裂纹、毛刺和断裂做框检测。改进YOLOv4能检测微小缺陷，但模型过大，不利于在线部署。

在BN缩放系数上加L1稀疏约束，使部分通道更容易被筛掉；先做90%通道剪枝，再删两层。删掉的是实际结构，不能理解成仅把部分权重改成零。

用未压缩模型作为教师，学生同时学习真实标注和教师的软类别输出，并加入边框回归约束。温度让类别分布更平滑；边框约束避免教师在学生已经更好时过度干预。部署时只使用学生。

结果怎样读

自建1200张、4类、80/20划分；输入416×416。Table 5为压缩阶段结果，Table 6分别列RTX 2080Ti与Jetson AGX Xavier速度。

阶段	参数 / 文件大小	检测指标
原模型	63,953,841 / 244 MB	97.50%
通道+层剪枝	1,080,754 / 4.19 MB	95.14%
剪后蒸馏	学生结构不增大	mAP 97.41%

无KD微调曲线最优96.05%，KD后97.41%；最终学生在AGX Xavier为47.8 FPS。但缺原始大模型同板基线，不能计算“压缩导致板端加速多少倍”。Table 6将该检测指标列为mAP，不能翻成普通分类正确率。

我能学到什么，对我的方向有什么用

从阶段表读清谁负责压缩、谁负责恢复；较好的实验应保留“剪后未微调、普通微调、KD微调”三个节点。 可做的小实验：在自己的数据上先锁定测试集，做温和结构化剪枝，再在同预算下比较无KD/KD；重测导出和量化后的精度。

保留的限制与原文入口

原文明确说测试集用于调超参数，会产生乐观偏差；私有数据限制复现。不同表和曲线中的基准精度不完全一致，板端计时范围、精度模式也不充分。90%剪枝不是可直接套用的默认配置。

读图路线：把Table 5的压缩损失与Fig.21–22的精度恢复连起来，再到Table 6确认47.8 FPS具体属于哪台设备。

原文定位：§2.2、实验部分；PDF pp.10–13、16、19–23；Table 4–6、Fig.21–22。

2026 · Scientific Reports | 部署基准 | 精读

P03 | Rockchip基准：FLOPs为什么预测不了板端速度

一句话抓住贡献

对RK3568方向，最值得复用的是测量方法，而不是某个模型的公开FPS。

写了什么：问题与方法

在低算力SoC上，模型参数、FLOPs与芯片标称TOPS都不足以解释真实延迟。论文考察架构、输入分辨率、内存争用、NPU调度与每帧能量。

比较YOLOv5/v8/11各n/s/m，共9种模型；执行PyTorch→ONNX→RKNN→NPU。详细设置为Toolkit 2.3.0、64张COCO验证图作校准、PTQ；前文又写部分中型模型用QAT，存在叙述冲突。

对RV1106、RK3568、RK3588扫描输入尺寸，并加入CPU/内存压力；100次推理中去掉前10次热身。使用外接USB功率计测稳态平均功率，再由功率乘时间求单帧能量。

结果怎样读

COCO通用框检测，不是工业缺陷。Table 2的COCO mAP不能当作每块板重新测得的INT8准确率；本文的end-to-end指NPU runtime范围，不等于相机到报警全链路。

同一YOLOv5n@640	平均功率	单帧能量
RK3568	2.22 W	75.52 mJ/frame
RK3588	3.45 W	74.93 mJ/frame

功率更高却可能因更快完成一帧而能量相近。模型更“新”或FLOPs更低也未必更快；大特征图与系统内存争用可能抵消计算优势。相关性不能解释成“精度高本身导致速度慢”。

我能学到什么，对我的方向有什么用

建立延迟、带宽、负载、功率与能量的系统视角；学习把网络选择问题变成目标硬件上的实测问题。 可做的小实验：把工业测试集、CPU回退日志、p50/p95延迟、相机采集和后处理加入同一协议；校准集独立于最终测试集。

保留的限制与原文入口

缺同设备浮点与INT8的最终精度闭环；PTQ/QAT叙述冲突；其多核NPU实验主要对应RK3588，不能照搬到RK3568。COCO经验不证明微小缺陷不会量化掉点。

读图路线：Fig.2学习转换链路，Fig.3比较同板模型，Fig.6看系统压力，Table 5区分W和mJ/frame。

原文定位：Methods与Results；PDF pp.3–11；Fig.2–7、Tables 1–5。

2023 · CVPR | 剪枝基础 | 精读

P04 | DepGraph：剪一个通道为什么要连带改很多层

一句话抓住贡献

剪枝首先是一个结构一致性问题，其次才是通道重要性排名问题。

写了什么：问题与方法

残差、拼接、归一化和多分支网络中，独立剪某层容易产生维度不匹配；手写每种网络的关联规则成本很高。

把每层拆成输入侧与输出侧的剪枝关系，建立相邻操作的依赖图；从一个待删通道递归传播，找到必须同步删除的参数组。Add要求相关分支匹配，Concat则需要正确跟踪通道区间与索引。

在完整依赖组上计算重要性与施加一致稀疏约束，再联合删除；重要性可以先用简单范数。论文对比不分组、只考虑卷积和完整分组，说明漏掉耦合参数会影响精度与稳定性。

结果怎样读

主要为CIFAR、ImageNet分类，另有文本、点云、图任务；这里记录ImageNet ResNet-50的top-1，不是检测mAP。

ImageNet ResNet-50	top-1准确率	MACs
原网络	76.15%	4.13G
DepGraph剪后	75.83%	1.99G

以0.32个百分点top-1代价减少计算规模，证明依赖分组的可用性；MACs下降不等于已经测出RK3568加速倍数。论文通用性也不意味着任意自定义YOLO模块均可直接处理。

我能学到什么，对我的方向有什么用

理解“上一层输出通道删掉，下一层对应输入也要删”；残差和拼接必须跟着检查。不要把不报维度错误当成检测语义仍正确。 可做的小实验：给YOLOv8剪枝前保护类别数、边框输出维度及必要分支；每次小幅剪枝后检查前向、训练、ONNX输出与RKNN转换。

保留的限制与原文入口

原文不提供工业检测与RKNN部署闭环；自定义算子、检测输出层、静态导出需要单独适配，不能直接拿分类表支撑工业漏检改善。

读图路线：Fig.2先看Add/Concat依赖，Fig.3看递归传播，Fig.4理解为什么依赖组要整体稀疏；最后再读Table 3。

原文定位：§3、§4；PDF pp.3–8；Fig.2–4、Algorithms 1–2、Table 2–3。

2022 · CVPR | 蒸馏基础 | 精读

P05 | FGD：教师的前景、背景与全局关系怎么教

一句话抓住贡献

检测蒸馏的关键不是让学生抄下整张特征图，而是决定哪里、哪些通道以及什么关系值得学。

写了什么：问题与方法

缺陷区域通常很小，背景像素远多于目标。教师与学生在不同区域的差异不均，直接把所有特征同等匹配可能让背景主导学习。

Focal蒸馏按真实框划分前景/背景，分别归一化并分配权重，再利用教师的空间注意力和通道注意力强调关键位置。背景不应一律丢弃，它能帮助抑制误检。

Global蒸馏传递像素之间的全局关系，补足局部匹配丢失的上下文。总损失由原检测损失加局部/注意力/全局项组成；这些训练辅助分支通常不进入学生推理图。

结果怎样读

COCO 2017框检测；RetinaNet、Faster R-CNN等多种检测器。下表为RetinaNet-ResNet50学生；更强教师为RetinaNet-ResNeXt101。

同一学生	COCO box AP	说明
无蒸馏	37.4	学生基线
FGD	40.4	不加继承策略
FGD+继承策略	40.7	教师/学生检测头兼容

常被引用的+3.3 AP包含额外继承策略；不应写成任意教师配置下FGD都能提高3.3。学生结构固定，KD改善精度而非再次删参数。消融表显示局部与全局信息具有互补性。

我能学到什么，对我的方向有什么用

从“等权蒸馏并不好”这一反例建立动机，再用拆分消融证明设计；学会报告教师、学生、特征层与额外初始化策略。可做的小实验：固定剪后学生，比较无KD、普通特征MSE、前背景分离、再加全局项；同时看小缺陷召回与背景误检。

保留的限制与原文入口

COCO目标与工业重复纹理不同，框内也未必全是缺陷；教师错误会被传给学生，损失权重、特征对齐和训练成本需要重新评估。没有RK3568实测。

读图路线：Table 1回答“为何分前背景”，Fig.2解释机制，Table 3确认40.7的脚注，Table 4检查局部/全局互补。

原文定位：§3–4；PDF pp.2–7；Table 1、3、4、Fig.2。

2020 · ICML / PMLR 119 | 量化基础 | 选读

P06 | AdaRound：最接近的取整不一定最保精度

一句话抓住贡献

量化应尽量保留网络输出，而不只是让每个权重的数值误差最小。

写了什么：问题与方法

权重四舍五入虽然单个数最接近原值，但多个舍入误差会一起作用，可能改变一层输出并逐层累积。

从任务损失的二阶近似出发，把每个权重的向上/向下舍入写成二元选择；为降低复杂度，转成逐层输出重构问题，用少量无标签数据指导舍入。

以连续软变量近似二元选择，前期优化重构，后期正则把决定推向0或1；采用非对称重构，让已量化前层的实际输入误差进入当前层优化，并考虑激活函数。PTQ也可以有优化迭代，不等于不做任何计算。

结果怎样读

ImageNet分类，另测Pascal VOC语义分割；正文及官方补充材料已取得。4W/32A表示权重4位、激活32位，不是全网络4位。

同设置ResNet18	top-1准确率	定位
最近舍入	23.99%	Table 8
偏置校正	38.87%	Table 8
AdaRound	68.60±0.09%	Table 8

该特定低位宽设置中，自适应舍入显著减少精度损失；不能由此推断RKNN INT8会有同样幅度收益。Table 7另有4W/8A结果，不能混用设置。这里的top-1和分割mIoU都不是缺陷检测mAP。

我能学到什么，对我的方向有什么用

学会追问量化位宽、量化粒度、校准图像和重构目标；无标签校准图也应覆盖真实亮度、材质和缺陷大小。 可做的小实验：先跑通受支持的RKNN INT8基线；若精度下降，先检查校准覆盖、逐层误差与输出，再决定是否值得研究更复杂PTQ。

保留的限制与原文入口

没有工业框检测/NPU部署证据；4-bit数值实验不证明RK3568硬件支持相同格式或会加速。转换编译可能重新量化，不能默认保留AdaRound的舍入决策。

读图路线：先看Table 1的舍入反例，再读Table 4的重构改进；Table 7先辨认W/A位宽，Table 8才是上述公平对照。

原文定位：§3–5；PDF pp.3–9；Eq.21–25、Table 4、7–9；补充材料另存。

2025 · PLOS One | 量化+部署 | 对照阅读

P07 | YOLO11+RK3568：学工程链路，也学识别统计问题

一句话抓住贡献

它能证明有RK3568部署案例，但其精度和跨平台加速数值需要独立重算。

写了什么：问题与方法

工件缺陷数据有限、云端传输存在开销，希望用数据增强改善检测，并把YOLO11放到低成本边缘设备。

用翻转、裁剪与SA-GAN生成更多训练样本；SA-GAN借助自注意力关联远处纹理与缺陷。生成图只应增强训练集，不能与同源测试图交叉。

将模型经ONNX转为RKNN，使用非对称INT8、通道级量化与误差优化设置；在RK3568加载运行。归一化、通道顺序和后处理必须与训练侧一致。

结果怎样读

NEU中选用夹杂、斑块、划痕等部分类型并增强；另测天池铝型材，不是标准NEU全6类同配置。训练RTX4090；部署RK3568。

作者Table 8所列	模型大小	单图时间
桌面FP32模型	10,156 KB	52.1 ms
RK3568 INT8模型	4,194 KB	33.6 ms

这是跨硬件、跨精度前后对照，不能归因成“量化让同一RK3568提速35.5%”。更关键的是PDF p.13 Eq.12把AP写为(P+R)/2，区别于PR曲线面积；作者的mAP数字不宜未经重算当作标准检测mAP。

我能学到什么，对我的方向有什么用

把数据增强、网络选择、量化与平台迁移拆成独立问题；阅读工程论文也要检查最基础的评价公式。 可做的小实验：借鉴转换流程；重新用标准评估器，在同一固定测试集上比较PyTorch、ONNX和板端RKNN输出，分别记录NPU与整链路延迟。

保留的限制与原文入口

输入尺寸/样本数等叙述不一致，缺校准集、最终标准mAP、同板基线和充分计时定义。正文的采集到返回低于150 ms描述不等于已经给出完整重复测量分布。

读图路线：Fig.6看转换链路，Table 8先标出两台设备，再回到Eq.12。学会把“系统能运行”和“数值结论可靠”分开判断。

原文定位：PDF pp.8–13、19–20；Eq.12、Tables 2、8、Fig.6。

2026 · Sensors | 组合压缩+部署 | 进阶

P08 | YOLO-RMF：INT8竟然可能比FP16慢

一句话抓住贡献

最值得研究的现象，是剪枝、量化和后端执行之间存在交互，而非效果简单相加。

写了什么：问题与方法

低对比、多尺度带钢缺陷需要局部细节和长程上下文，但增加模块可能破坏边缘效率。

RPRC2用两级2×2卷积、复制填充与SiLU；此处重参数化是各自Conv-BN融合，中间非线性使两级卷积不能整体折成一个。TDAA沿高、宽分别做注意力，MSF-FPN融合尺度，FDetect共享部分特征提取。

以BN系数与特征图秩组成混合通道分数，再剪枝、KD微调和TensorRT部署。35%是作者的剪枝策略配置，实际参数减少36.3%、GFLOPs减少49.0%；三者不是一个数。

结果怎样读

NEU-DET与MVIT；640×640。下表仅为Jetson AGX Orin、Table 8的推理结果，不能拿桌面mAP补成最终量化引擎精度。

同板模型 / 精度	推理延迟	内存
未剪 / FP16	6.8 ms	512 MB
未剪 / INT8	7.9 ms	328 MB
剪后 / FP16	5.9 ms	345 MB
剪后 / INT8	4.3 ms	218 MB

未剪模型INT8更慢，剪后INT8才显著改善；作者解释为算子回退、类型转换和带宽影响，但因果机制仍需日志/算子性能证实。233 FPS是推理吞吐；Table 9总延迟6.3 ms，对应约158.7 FPS。

我能学到什么，对我的方向有什么用

从反常结果提出可检验机制；模型小、低位宽和实测快是三件事。看产线速度还要检查视野、帧间覆盖和端到端延迟。可做的小实验：在RK3568上做剪枝×量化的2×2实验，记录回退算子、转换开销和p95；优先从标准卷积学生开始，再单独加轴向注意力。

保留的限制与原文入口

缺Table 8各最终引擎mAP；固定seed0与十次独立训练叙述未对齐，模型配置及部分统计表有不一致。25W模式不是实测平均功率。

读图路线：Table 4辨别策略比例与实际压缩，Table 8找INT8反例，Table 9核对233与158.7 FPS各自的时间边界。

原文定位：§3.2–3.7、§4.3–4.10；PDF pp.6–17、20–23；Table 4、8、9。

2023 · Applied Sciences | 迁移+剪枝+蒸馏 | 选读

P09 | 弧形磁瓦：压缩九成不代表时间也降九成

一句话抓住贡献

它把小数据迁移、结构压缩与漏检敏感训练连起来，也展示了规模和速度不成比例。

写了什么：问题与方法

弧形磁瓦缺陷样本有限，既要识别裂纹、气孔等多种缺陷，又希望得到较小模型。

先在COCO上预训练YOLOv5s，再冻结/解冻迁移到磁瓦；按卷积通道L2范数剪枝，作者选择75%配置。预训练解决初始化，剪枝解决规模，两者作用不同。

未剪迁移模型做教师，剪后模型做学生；在置信度蒸馏损失中加入λ，改变对缺陷的敏感程度。更重视漏检可能带来正常件误报，因此还要单列无缺陷样本表现。

结果怎样读

作者由原始/补充样本扩展，再增强为18,770张、约8/1/1；416×416。GPU原文写作“GTX3050Ti”，型号命名异常；不是ARM/NPU测试。

最终模型 / 相对YOLOv5s	作者结果	含义
文件大小	1.921 MB	不等于运行内存
参数 / FLOPs	−93.505% / −88.337%	多阶段总体差异
平均单图时间	9.46 ms，−12.867%	时间收益远小于规模降幅

作者报告AD=100%，但AD更接近缺陷总体检出指标，不是100%框mAP，也不保证未来所有缺陷零漏检。少量正常磁瓦仍被误报，说明召回与误报必须一起评估。

我能学到什么，对我的方向有什么用

关注业务代价：漏过裂纹和错报正常件是否同样严重？把检测阈值固定或给PR曲线，才能公平解释所谓“准确率提升”。 可做的小实验：沿工件编号分组后再增强；固定漏检约束下比较误报和p95延迟，用Pareto选择取代把MB与百分比直接相加。

保留的限制与原文入口

增强后划分的同源隔离需核实；AD公式文字中FN释义有笔误。剪枝率目标函数直接相加百分比与MB，量纲/尺度任意，不能当通用最优准则。缺板端和能耗证据。

读图路线：Fig.6看75%怎么选，Fig.8同时看缺陷与正常件，Fig.9不要把模型大小柱的降幅理解成时间柱的降幅。

原文定位：§2.4、§3.2–3.4、§4.3–4.6；PDF pp.9–11、13–19；Eq.12–13、Fig.6–9。

2025 · PLOS One | 剪枝+蒸馏+部署 | 问题式精读

P10 | LNB-YOLO：贴近RK3568，但仍须补齐证据

一句话抓住贡献

它很贴近你的硬件，但最值得借鉴的是可复现的问题清单，不是直接照搬全部模块。

写了什么：问题与方法

手机表面油污、划痕和污渍较小，原始YOLO特征可能丢失；希望提升检测并压缩部署。

CGRFPN重建和融合深浅层特征，ELA沿横纵方向聚合位置信息，LSDECD通过共享卷积与细节增强降低头部冗余，MPDIoU约束框角点距离。

用LAMP评分决定稀疏分配，以特征通道的空间分布KL蒸馏恢复能力，再导出ONNX/RKNN。正文称“非结构化”却又报告通道/参数大幅减少，真实剪枝实现需从代码和导出结构核验。

结果怎样读

PKU-Market-Phone，增强后1800张、6/2/2划分，640×640；另测PCB。板端验证仅20张图、77个目标。最终位宽与校准方案未明确，不能仅凭.rknn认定INT8。

同一LNB结构	参数 / FLOPs	mAP50 / 50:95
未剪	3.4M / 6.7G	96.4% / 69.2%
66.7%策略+KD	0.6M / 3.0G	97.5% / 68.8%

mAP50提高1.1个百分点，较严格的50:95却下降0.4；定位质量并未全面改善。正文桌面FPS不能当板端FPS，论文没有足够板端计时支持“压缩带来多少提速”。

我能学到什么，对我的方向有什么用

同看两个mAP口径；检查稀疏掩码与实际删通道的区别；板端照片能证明运行存在，却不能代替量化、速度和长期稳定性评估。 可做的小实验：先复现标准YOLOv8n的RKNN链路，逐项检查剪后ONNX通道数，再补无KD/KD、量化前后和完整板端测试。

保留的限制与原文入口

Table 9的LNB-Stain为TP=21、FP=2、FN=2，按定义精确率和F1都约91.3%；Table 10却列87.0%和89.1%，故Table 11宏指标也需回算。小样本及统计检验不能替代独立重复训练。

读图路线：Table 6读双mAP，Fig.6核查剪枝单位；Table 9→10手算一类指标，再看Fig.10的工程系统。

原文定位：PDF pp.5–14、17–22；Eq.16–22、Tables 5–6、8–11、Fig.6–7、10。

2026 · Scientific Reports | 剪枝+蒸馏 | 精读

P11 | BFCD-KD：把特征、类别和边框一起教给学生

一句话抓住贡献

用同一个剪后学生比较不同KD损失，最容易看清“压缩代价”和“恢复收益”。

写了什么：问题与方法

增强YOLOv8的表征能力后，参数与计算量上升；希望通过剪枝保留强教师的能力。

以已有SAF-YOLOv8n为教师，方法节按卷积核L1范数评估并删过滤器；保护检测输出和核心重构层。摘要的L1正则化措辞不能替代对实际剪枝单位的核查。

BFCD-KD组合Mimic中间特征匹配、差异感知的二元分类蒸馏与CIoU框定位蒸馏，加上原检测损失。分类头使用Sigmoid，不能不加分析地照搬互斥Softmax分类蒸馏。

结果怎样读

GC10-DET、640×640、RTX4090。没有真实ARM/NPU速度测试；相机+PyQt界面不等于开发板推理证据。

阶段 / KD方式	参数 / FLOPs	mAP50 / 50:95
SAF未剪	4.1M / 14.7G	70.8% / 35.4%
50%策略剪后	2.4M / 7.2G	67.5% / 32.4%
同学生+特征KD	2.4M / 7.2G	70.1% / 33.7%
同学生+BFCD-KD	2.4M / 7.2G	70.6% / 34.8%

KD恢复3.1个百分点mAP50，学生规模没有再变。相对SAF教师，参数约少41.5%、FLOPs少51.0%；相对原始YOLOv8n的3.0M/8.1G则仅少20.0%/11.1%，分母决定“压缩多大”。

我能学到什么，对我的方向有什么用

特征告诉学生看什么，类别告诉它判什么，边框告诉它框哪里；从最简单的特征KD起步，再判断加输出KD是否值得。可做的小实验：固定教师检查点与学生结构，做无KD、MSE、输出KD、联合KD四组，同训练预算；再在RK3568测最终引擎。

保留的限制与原文入口

正文部分参数/FLOPs顺序颠倒，本报告依据表格单位。方法说明有“相同通道特征”条件，剪后如何选层/对齐需落到代码；缺量化、同板延迟与充分统计不确定性。

读图路线：Table 2找剪枝损失，Table 3在同一学生内找恢复；Fig.6确认通道真的变少，别只看摘要百分比。

原文定位：PDF pp.3–8、10；§Filter pruning、KD实验；Tables 2–4。

2026 · Journal of Imaging | 架构+量化 | 精读

P12 | PCB+TensorRT：P2保细节，INT8也会掉精度

一句话抓住贡献

最适合学习“小缺陷表征”和“实际量化损失”如何同时权衡。

写了什么：问题与方法

PCB中的鼠咬、毛刺、开短路尺度小、边界细，既要轻量又要精确定位。

以YOLOv8-L为基线，RepGhost以廉价特征生成减少卷积冗余，CA沿坐标方向聚合信息，P2增加高分辨率检测路径以保留微小目标，WIoU调整回归损失。

架构改进后另外构建TensorRT FP32、FP16和INT8引擎。P2改善细节也增加高分辨率特征成本：Table 4中加P2使参数27.6M→34.0M、FPS 36→34，说明它并非无成本增益。

结果怎样读

公开PCB693张与自建6319张混合，640×640；约80/20。下表是RTX4070桌面TensorRT结果，不是Jetson，更不是RK3568。

精度模式	延迟 / 文件大小	mAP50
FP32	19.6 ms / 70.4 MB	97.6%
FP16	15.4 ms / 50.5 MB	97.4%
INT8	12.2 ms / 32.3 MB	95.8%

INT8相对FP32时间降约37.8%，同时损失1.8个百分点mAP50；是否值得取决于漏检约束，不能只挑82 FPS。该表与架构消融的30/34 FPS测试配置不同，不能拼成同一前后链。

我能学到什么，对我的方向有什么用

把“省计算的模块”和“补精度的模块”分开看；模型文件大小不是峰值RAM，.engine也不能直接放到Rockchip执行。 可做的小实验：对自己的YOLOv8n做有/无P2与量化交互实验；优先看小缺陷召回、内存和p95，而非只看总体mAP。

保留的限制与原文入口

私有数据占大多数，同产线固定成像；缺独立测试/跨产线验证。未充分给校准集、引擎混合精度、batch、计时范围与量化后的分尺寸召回。

读图路线：Table 4看到P2的精度/成本交换，Table 5看到INT8的速度/精度交换；Fig.11解释仍然难检的小缺陷。

原文定位：§2.2与实验；PDF pp.4–8、13–14；Table 4–5、Fig.11。

2025 · Electronics | 非YOLO+蒸馏 | 进阶

P13 | RT-DETR-FFD：跳出YOLO，看纹理与蒸馏

一句话抓住贡献

参数减少而速度下降的例子，能帮助你避免把“轻量”当成单一指标。

写了什么：问题与方法

印花织物具有周期纹理，纹理与缺陷相似；需要兼顾局部异常、全局结构与轻量检测。

FCSM用空间/傅里叶分支建模周期与异常，FF-Net用多分支和StarBlock融合特征，LPE学习位置信息。频域可帮助区分纹理与异常，但不能把所有背景等同低频、所有缺陷等同高频。

用RT-DETR-X教师指导改进R18学生；DCG蒸馏动态选择局部区域，并传递全局通道关系。非显著区域保留部分权重，避免完全切断信息。

结果怎样读

天池印花织物2318张增强到3528张，7/2/1划分；另有Denim；640×640、RTX3090。不是板端部署，也不是仅正常样本训练的异常检测。

模型	参数 / FPS	mAP50 / 50:95
R18基线	19.88M / 66.2	75.8% / 51.0%
改结构、无KD	17.56M / 57.3	80.3% / 57.6%
同结构、DCG KD	17.56M / 57.3	82.1% / 60.3%

结构修改使参数更少但更慢；KD在固定学生下提高1.8/2.7个百分点，推理速度不变。与CWD、MGD的损失对照有助于区分KD贡献。不能把速度下降归咎于训练时KD。

我能学到什么，对我的方向有什么用

学习非YOLO的检测思路及公平蒸馏实验；用频域假设提出实验，而非把论文中的直觉当成普适规律。 可做的小实验：借用动态掩码/局部全局蒸馏思想，先用于可导出的卷积学生；完整RT-DETR复刻放在RKNN兼容性核查之后。

保留的限制与原文入口

五次运行只给均值、未完整给方差；增强后划分同源隔离需查。FFT、注意力等算子迁到RKNN的可行性未知，17.56M也不是低成本NPU上的轻量保证。

读图路线：Fig.2看频域分支，Table 5横向拆开结构与KD，Table 6比较损失；热力图只能辅助说明，不能代替检出统计。

原文定位：§2.2–2.7、§3.1–3.10；PDF pp.4–11、15–17；Table 4–7、Fig.2、7。

2025 · Applied Intelligence | 原生架构+部署 | 选读

P14 | YOLO-MSD：原生小网络也要看实际资源

一句话抓住贡献

它提供多尺度与资源测量参考，但Tiny不是从X剪出来的模型。

写了什么：问题与方法

高分辨率工业图像中，小缺陷和大缺陷并存；需要在网络容量、尺度融合与设备资源间选择。

MSCNet骨干在多个尺度并行提取与交换特征，SFPN简化融合路径，anchor-free检测头减少部分卷积；通过宽度/深度等配置形成X/L/M/S/Tiny系列。

在PCB、HRIPCB、GC10-DET、NEU-DET、CRACK上测试，并在Jetson Xavier NX报告速度、最大RAM、峰值温度和最大功率。本文没有实施可据以确认的剪枝/KD/PTQ流水线。

结果怎样读

下表来自Table 15的同板PCB实验，框mAP名称保留原文；大尺寸输入影响速度，不能与其他论文640×640直接排位。TensorFlow 2.11，原文未说TensorRT。

Xavier NX型号	mAP / FPS	最大RAM / 最大功率
X	95.86% / 3.38	2210 MB / 14.59 W
L	96.67% / 4.95	2099 MB / 13.11 W
Tiny	90.64% / 20.82	1359 MB / 6.95 W

Tiny速度更快、资源较少，也牺牲精度；96.67%的最高mAP属于L，不能和Tiny的20.82 FPS拼成一个配置。最大功率不可当平均能量来算每帧消耗。

我能学到什么，对我的方向有什么用

部署报告应同时给精度、速度、RAM与功率，并保持同型号配对；原生小网络应作为压缩网络必须击败的基线。 可做的小实验：以Tiny/n级原生网络作为对照，问“剪大模型再KD是否优于直接训练小网络”；借用资源报告维度，不默认迁移TensorFlow到RKNN无成本。

保留的限制与原文入口

框架、输入与设备条件影响可比性，缺完整热身/batch/测量边界；公开多数据集上的重新训练表现，不等于跨产线零适配泛化。HRIPCB旋转同源测试也需区别真实成像域迁移。

读图路线：Fig.3理解多尺度传递，Table 15逐行配对精度与资源；先确认所读的是哪一型号，再解释最高值。

原文定位：§2、§3.1、§3.2.6；PDF pp.4–8、15；Table 8、15。

2024 · Symmetry | 剪枝比较 | 选读

P15 | YOLO-RDP：怎样分开网络改进与剪枝收益

一句话抓住贡献

比起只展示最终模型，这篇的阶段消融和多准则对照更值得学。

写了什么：问题与方法

钢材微小缺陷的检测头增强会增加成本，希望再通过轻骨干、轻颈部和通道剪枝平衡规模。

在YOLOv7-tiny上使用ReXNet、GSConv/VoVGSCSP，再用DdyHead结合动态与解耦头思想，改善尺度、空间和任务适配。检测头加强同时也增加参数/FLOPs。

比较L1、LAMP、Slim及分组类共六种剪枝方案，最终用BN稀疏相关的Slim通道剪枝。先增强再压缩形成完整链路，但不能把全部增益记给剪枝。

结果怎样读

NEU-DET与GC10-DET，640输入；GPU方法实验。原文“RTX3090、32GB显存”配置有疑点，本报告不据此推断边缘速度。mAP沿用表名，不擅自升级为COCO AP。

数据集 / 阶段	参数 / FLOPs	mAP
NEU：改进未剪	6.87M / 14.9G	79.2%
NEU：再Slim剪枝	3.51M / 9.95G	79.8%
GC10：改进未剪	6.87M / 14.9G	74.0%
GC10：再Slim剪枝	4.21M / 9.9G	76.4%

在作者设置下，剪后mAP略升，可能涉及正则化和再训练，不能由单次表格证明剪枝天然提高泛化。NEU剪后Precision还由86.2%变67.0%，Recall由70.0%变77.9%，须连同阈值与PR曲线解释业务代价。

我能学到什么，对我的方向有什么用

剪枝准则要在相近压缩目标和训练预算下比较；看逐阶段消融，能识别“增精度但变重”的模块是如何被后续压缩抵消。 可做的小实验：在同一YOLOv8学生上比较L1、BN-Slim与依赖组准则，匹配FLOPs/预算；在RK3568重新测实际延迟与分类型召回。

保留的限制与原文入口

没有真实ARM/NPU验证；文中1.5×是剪枝比较目标，非已测板端提速。结论提到weight quantization不代表执行了PTQ/QAT；自定义动态头增加导出风险。

读图路线：Table 4–5看不同准则，Table 6–7用倒数两行隔离剪枝增益；Fig.8–9检查通道变化位置。

原文定位：§3–4；PDF pp.4、7–8、11–13；Table 4–7、Fig.7–9。

数值图解一 | 数据保留原文口径，无跨论文排行榜

同论文内看清：规模、速度和精度不是一回事

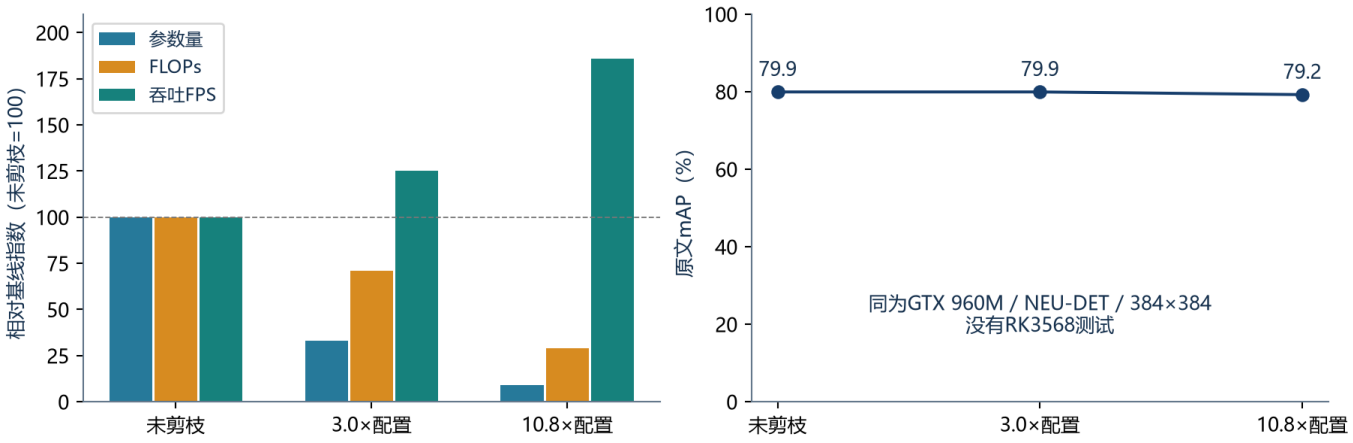


图3 | P01 Table 2重绘。左图各指标分别除以自身未剪基线×100；右图mAP保留0–100坐标，无误差线因原表未给。

RDDPA参数从6.7M到0.6M，但FPS只从21.6到40.1：吞吐约1.86倍。内存也仍有激活、缓存和运行库开销，因此不会按参数比例缩小。此图只能说明该配置的有限现象，不能证明所有剪枝网络都有同一规律。

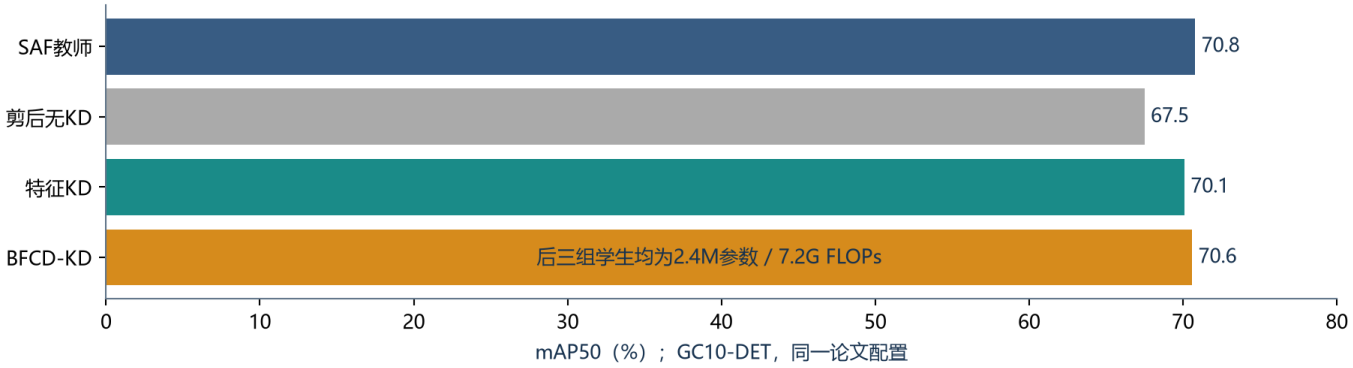


图4 | P11 Tables 2–3重绘。教师与学生先区别，后三组学生结构固定；横轴从0起。

BFCD-KD把剪后67.5%恢复到70.6%，恢复3.1个百分点；距教师70.8%仍差0.2。该实验支持“训练监督能补回部分剪枝损失”，未支持“KD本身使板端更快”。

用表格做因果归因

原生模型→增强教师，回答架构收益；教师→剪后学生，回答压缩代价；固定学生无KD→有KD，回答训练监督收益；同一学生浮点→INT8，回答量化代价。任何跳过中间节点的对照都更难归因。

数值图解二 | 每张图各自保持硬件和模型配对

同论文内看清：低位宽的收益有条件

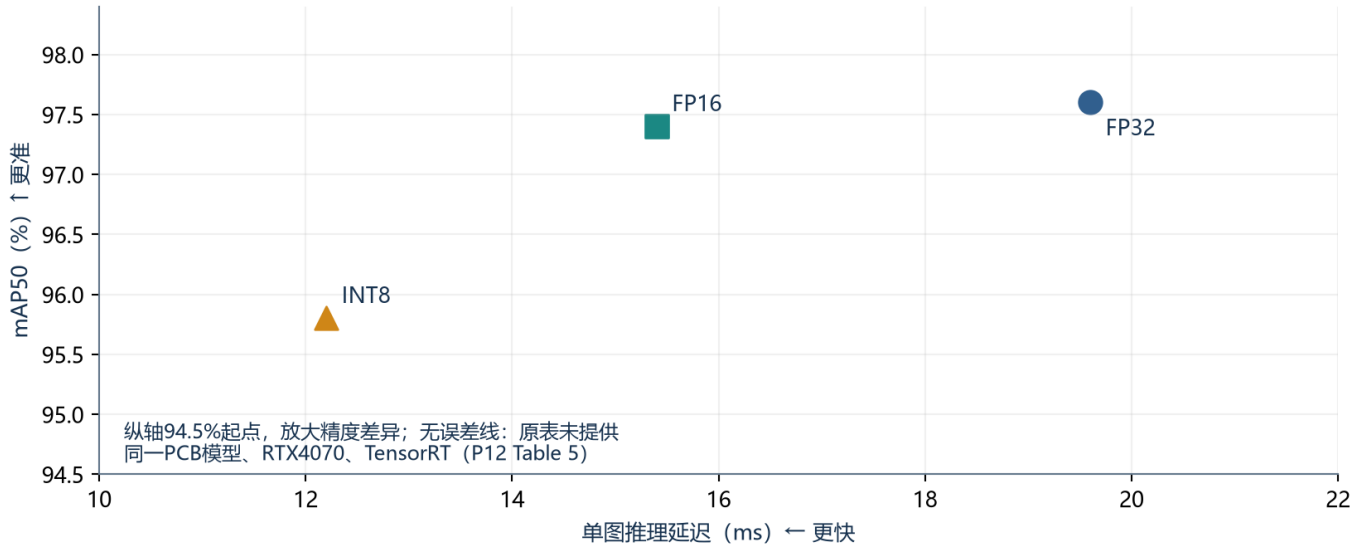


图5 | P12 Table 5，RTX4070。散点纵轴放大精度变化，未给误差范围；三种配置都存在速度/精度取舍。

FP16仅损失0.2个百分点mAP50，INT8损失1.8个百分点而更快。是否选择INT8必须先定义可接受的漏检与定位损失；“只看最右一列/只看最快点”都不能完成工程决策。

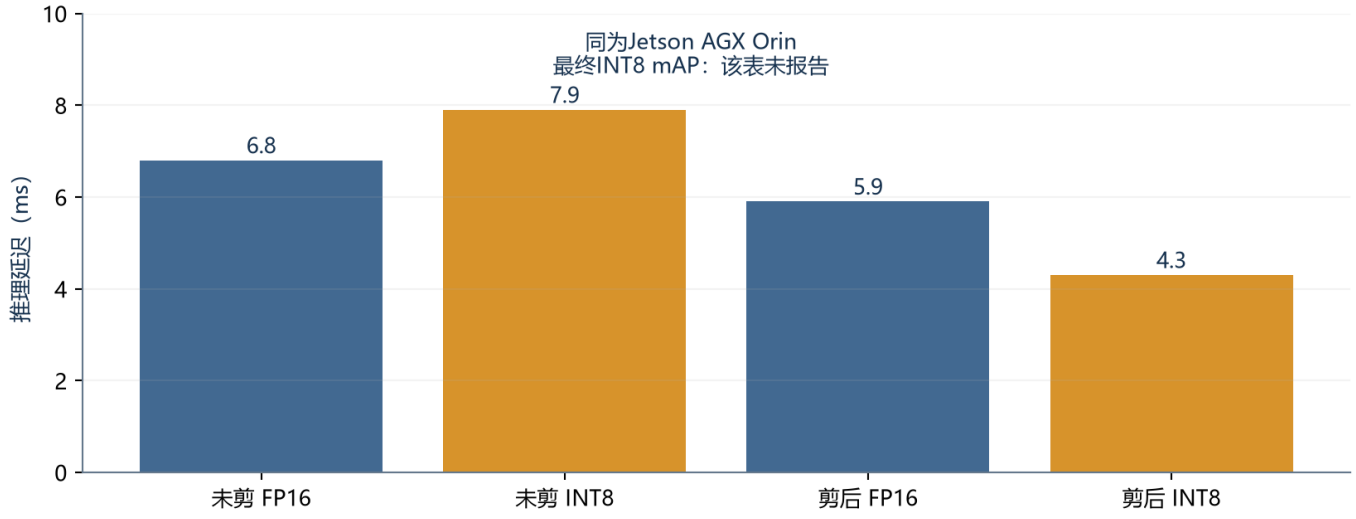


图6 | P08 Table 8，Jetson AGX Orin。延迟从0起；没有把未报告的最终INT8精度补进图中。

同板未剪模型INT8的7.9 ms慢于FP16的6.8 ms；剪后INT8为4.3 ms。量化效果受结构影响，是值得研究的交互。应进一步查算子回退、内存访问与转换，但本表本身尚未证明哪一个机制主导。

原文核验案例 | 公式、计数与派生值必须相符

两次手算：让你具备核查论文的能力

案例A：AP不是精确率与召回率的平均值（P07）

$$PRE = \frac{TP}{TP + FP}$$

$$REC = \frac{TP}{TP + FN}$$

$$F1 = 2 \times \frac{PRE \cdot REC}{PRE + REC}$$

$$TNR = \frac{TN}{TN + FP}$$

$$AP = \frac{\mathrm{PRE} + \mathrm{REC}}{2}$$

$$mAP = \frac{\sum AP_C}{N}$$

原文摘图 | P07 PDF p.13 Eq.8–13，重点为Eq.12；保留原式，不作为正确公式示范。

标准AP来自随置信度阈值变化的PR曲线面积；一个阈值处的(P+R)/2不能代替它。公式写错不必然证明作者代码也错，但缺评估代码与预测复算时，不能确认其“mAP50”与标准检测mAP可比。

案例B：计数和表中指标不一致（P10）

Table 9. Detection results of two models in PHONE_DATASET.

Network Model	Defect Types	Type of samples			
		TP Value	FP Value	FN Value	TN Value
YOLOv8	Oil	13	3	3	52
	Scratch	38	11	0	27
	Stain	14	2	9	51
LNB-YOLO	Oil	16	1	0	58
	Scratch	38	0	0	36
	Stain	21	2	2	54

https://doi.org/10.1371/journal.pone.0336971.t009

Table 10. Comparison of detection performance of two models for each defect category in PHONE_DATASET.

Network Model	Defect Types	Type of samples				
		PPV	FPR	FNR	TPR	F1-Score
YOLOv8	Oil	81.3%	5.5%	**18.8%**	81.3%	81.3%
	Scratch	77.6%	**28.9%**	0%	100%	87.4%
	Stain	87.5%	3.8%	**39.1%**	60.9%	71.8%
LNB-YOLO	Oil	94.1%	1.7%	**0%**	100%	97.0%
	Scratch	100%	**0%**	0%	100%	100%
	Stain	87.0%	3.6%	**8.7%**	91.3%	89.1%

https://doi.org/10.1371/journal.pone.0336971.t010

Table 11. Comparison of overall detection performance of the two models in PHONE_DATASET.

Network Model	Method	PPV (%)	FPR (%)	FNR (%)	TPR (%)	F1-Score (%)
YOLOv8	Macro	82.1	12.7	19.3	80.7	80.2
LNB-YOLO	average	**93.7**	**1.8**	**2.9**	**97.1**	**95.4**

https://doi.org/10.1371/journal.pone.0336971.t011

原文摘图 | P10 PDF p.21 Tables 9–11；LNB-Stain行是本次回算对象。

按Table 9：TP=21、FP=2、FN=2。Precision=21/23≈91.3%；Recall=21/23≈91.3%；F1=42/46≈91.3%。Table 10却给Precision 87.0%、F1 89.1%。因此不能把Table 11宏平均95.4%当作无需核对的可靠终点。需要作者原始预测与统一评估协议澄清；这里不擅自替换整篇实验结论。

基于这15篇的研究判断与建议，不是已经验证的新方法

对你的方向：把成像、检测和部署连起来

最适合你现阶段的主线是：在RK3568上研究结构化剪枝与检测蒸馏，并把微小缺陷、成像变化和最终INT8引擎作为共同约束。先用标准可导出卷积网络建立可信基线，再逐步加入一个有明确动机的改进，能减少“训练有效、上板失败”的返工。

候选方向	最小可检验问题	文献起点 / 必补证据
优先：压缩后微小缺陷保真	同压缩预算下，前背景或定位KD能否降低小裂纹漏检?	P04/P05/P11/P12；补分尺寸召回与最终INT8精度
优先：剪枝×量化×后端	FLOPs相近的候选，谁在RK3568更快、为什么?	P01/P03/P08；补编译日志、p95、资源与同板对照
扩展：成像变化下稳定性	亮度/对比/批次变化是否放大压缩与量化误差?	P08/P12/P14的局限；补真实跨批次/跨光照测试
综述：证据链与可比性	哪些部署收益可配对验证，哪些只是规模推断?	用本报告证据矩阵扩充检索，不把15篇当全领域

成像问题不一定能靠加模块解决

先估计原图中最小缺陷的像素尺寸：物理缺陷大小÷物面像素尺寸；再估计缩放到网络输入后剩多少像素。对整图等比缩放，像素尺寸约乘缩放系数；letterbox要按实际有效区域计算。模糊、反光与曝光饱和造成的信息缺失，后续放大或加P2不能自动恢复。

把“实时”换成产线约束

假设运动速度v、运动方向视野L、需重叠比例r，则理想无丢帧条件下$f \geq v/[L(1-r)]$。以P08讨论的25 m/s、125 mm视野为例，零重叠需200 FPS；本报告自设20%重叠时需250 FPS。其6.3 ms总延迟约158.7 FPS，不能因另有233 FPS推理吞吐就断言整链路满足该条件；还需考虑曝光拖影、触发和丢帧。

创新性如何判断

“YOLO+注意力+剪枝+KD+RK3568”已经有相邻工作。贡献应落在可验证假设、匹配预算的基线、可解释的后端机制、真实跨条件数据或可复现测量协议上；新颖性尚需专项检索，不能在此宣称。

experiment-design框架的任务化应用 | 本报告未执行训练或上板

把阅读变成实验：按四个阶段推进

阶段	该做什么	完成条件与交付
1 跑通最小链路	NEU-DET + 标准YOLOv8n；固定数据与种子，打通浮点→ONNX→RKNN→板端	保存版本、工件哈希、输入/输出样例与标准mAP；预后处理一致
2 建立可靠基线	增加GC10-DET；只调训练超参，不先叠复杂架构；比较原生小网络	训练曲线稳定；多种子结果；同板batch1、NPU与全链路计时
3 验证一个假设	加入真实工件或独立成像条件作为第三来源；研究剪枝×KD×INT8及小缺陷	一个主要假设有匹配预算对照，差异不仅来自训练更久或数据泄漏
4 消融与泛化	在相同数据来源上拆开KD项、剪枝准则和校准；跨批次/光照测试	均值/离散程度、分组误差、p95与资源齐全；失败例可复查

模型选择建议的范围

以YOLOv8n作为教学与排错起点，是因为这批应用论文有较多对应方法，不表示它在你的板上必定最优。依据P03，再增加可导出的同级YOLOv5n或YOLO11n作为硬件实测对照；只保留与你安装环境兼容的候选，并固定导出版本。

避免最常见的泄漏

先按工件编号、拍摄批次或时间段划分，再对训练集增强；同一原图的裁剪、旋转、GAN近似副本不得跨集合。验证集选剪枝率与校准配置；最终测试集锁定。另保留真实低光/反光/新批次作为外部条件测试，不把合成噪声测试等同真实跨产线验证。

计算预算有限时怎么做

先完成阶段1，再在两个数据集用少量候选筛选；将多种子完整评测集中于预先选定的最终候选。不要为凑齐15篇的模块而建立庞大搜索空间。本文建议三个种子作为起步，不能由此保证统计显著。

建议方案 | 所有格子目前均为计划，不是实验结果

最小实验矩阵：哪些比较才回答问题

组别	结构与训练	导出/量化	主要回答
A	原生n级模型，普通训练	浮点 + INT8	默认基线与量化损失
B	剪后学生，普通微调	浮点 + INT8	剪枝的独立代价与收益
C	与B同结构，特征KD	浮点 + INT8	简单KD能补回多少
D	与B同结构，任务相关KD	浮点 + INT8	复杂KD是否优于简单KD
E	直接训练与B相近预算的小网络	浮点 + INT8	压大模型是否胜过原生小网络
F（扩展）	同计算目标的另一剪枝准则	浮点 + INT8	重要性准则还是结构映射在起作用

固定与记录

固定数据划分、输入尺寸、教师、训练轮数/预算、增强和检测阈值；保留每个种子的日志。记录参数、FLOPs计数工具与口径，ONNX/工件哈希、编译器/runtime/驱动、板卡内存、频率与散热模式、校准图ID、实际精度/回退算子。

最终每个点至少要有这些结果

同测试集的mAP50与50:95、分类型/分尺寸召回和正常件误报；最终板端输出的精度回归；batch1的p50/p95、均值和离散程度，分别写NPU运行与采集到结果；峰值内存、持续运行温度、平均功率与同口径单帧能量。没有功率计则记未测，不用设备模式标签代替。

验收与选择

根据业务先确定允许漏检/误报、延迟上限与内存预算，再选不被其他方案同时在精度、延迟和资源上压过的点（Pareto候选）。若压缩后FLOPs更少但p95更差，就保留这个失败结果并查后端，而不是删除它。若目标板不能稳定运行，则不宣称部署成功。

一行实验记录模板：日期 | 数据划分/种子 | 教师/学生 | 剪枝单位/实际通道 | KD项/权重/预算 | 校准集/位宽 | 导出工件/版本 | 最终mAP与分组误差 | NPU/全链路p50/p95 | RAM/功率/温度 | 失败例路径。

先自己回答，再看解释；HTML可逐题展开

读完是否真的学会：10道自测

1. 参数少90%，为什么不代表速度快10倍?

执行还受激活、带宽、算子支持、调度和预后处理影响。P09总体参数约降93.5%，单图时间仅降约12.9%；这只是该实验的具体证据。

2. 剪枝后再KD，压缩是谁完成的?

删结构完成参数压缩；固定学生上的KD主要恢复精度。P11三种KD学生都为2.4M/7.2G。

3. P05的40.7 AP为何不能省略脚注?

对应强教师且使用继承策略，普通FGD在该表为40.4；不同教师/初始化不是同一实验条件。

4. P10 mAP50升、50:95降，是否矛盾?

不矛盾。宽松IoU检出改善，但更严格匹配下定位质量可能下降，必须结合分组与PR分析。

5. 为什么AP不能写成(P+R)/2?

P/R是单个阈值的点，AP需要跨阈值PR曲线的面积或相应插值计算。

6. PTQ是不是完全不需要优化?

不是。AdaRound仍优化舍入决策，只是不做常规的全网有标签重训；校准/重构可以有迭代。

7. 看到.rknn文件就能认定全INT8了吗?

不能。需要构建配置和日志确认实际层精度、输入/输出类型及回退；P10最终位宽未明确。

8. 233 FPS为何不能直接证明产线满足200 FPS?

233是特定推理吞吐；完整链路、视野覆盖、曝光、丢帧和重叠率也约束产线。P08总延迟倒数约158.7 FPS。

9. 真实板端照片与完整部署证据差在哪里?

照片证明运行存在，完整证据还需最终精度、同板延迟、重复稳定性与资源。P07/P10仍缺关键配对项。

10. 怎样证明你的新KD优于“只是多训练了一会儿”?

固定学生、教师与数据，加入同预算普通微调、简单KD、复杂KD，多种子评估，并在最终INT8工件上比较。

一分钟复述模板

这篇解决___问题，用___改变结构/监督/数值；在___数据、___设备与___计时范围下得到___；但缺___证据。我要借用___，通过___对照检验，不能直接声称___。

把本文变成可重复的阅读方法

以后读任何一篇，都可以走这条路线

顺序	问的问题	留下的笔记
1 任务与失败例	缺陷是什么、为何难？模型现在错在哪里？	一张失败图 + 真正业务约束
2 改了哪一层	改架构、剪结构、改训练还是改位宽？	流程图，标清训练与推理分界
3 找最关键的对照	能否只改变一个变量？分母是谁？	同一学生/同一板/同一数据的表行
4 核计量条件	mAP阈值、输入、batch、硬件、精度、计时	六要素和原文页/表/脚注
5 手算与反例	百分比、FPS倒数、计数指标能对上吗？	计算公式 + 不一致处
6 决定如何使用	借机制还是借数值？需要补哪个实验？	一个小假设与一组可执行对照

这些论文共同支持的认识

结构化剪枝与KD能够在各自设置下压缩并恢复检测能力（P01/P02/P09/P10/P11/P15）；任务相关蒸馏优于无差别抄特征有明确动机（P05/P11/P13）；低位宽的精度与速度收益依赖结构和后端（P03/P08/P12）。原生轻量网络也值得作为强对照（P14）。

这些论文还没有替你解决的事

你的最小缺陷能保留多少像素、你的相机和光源有何分布变化、你的RK3568编译后哪些算子回退、最终INT8学生是否稳定低漏检，以及持续运行时的p95和功耗，仍然需要自己的数据与硬件实验。

真正值得带走的能力

能够把“漂亮的最终数字”拆成可追溯的条件与因果链；能够把“可能有用的模块”改写成一个可失败、可验证的小实验。掌握这个，比记住十五个模型简称更能支撑研究。

正文标题、作者与年份为主；12篇期刊DOI已在线匹配Crossref标题

参考文献与原文入口 1–5

[P01] Kun Lu; Xuejuan Pan; Chunfeng Mi; Wenyan Wang; Jun Zhang; Peng Chen; Bing Wang. RDDPA: Real-time Defect Detection via Pruning Algorithm on Steel Surface. ISIJ International, 2024.

DOI: 10.2355/isijinternational.ISIJINT-2023-360；本地正文：论文\01_RDDPA_2024\正文.pdf。

元数据核验：Crossref返回标题匹配；作者/年份与正文对照。

正式来源页面

[P02] Qipeng Chen; Qiaoqiao Xiong; Haisong Huang; Saihong Tang; Zhenghong Liu. Research on the Construction of an Efficient and Lightweight Online Detection Method for Tiny Surface Defects through Model Compression and Knowledge Distillation. Electronics, 2024.

DOI: 10.3390/electronics13020253；本地正文：论文\02_微小缺陷_剪枝蒸馏_2024\正文.pdf。

元数据核验：Crossref返回标题匹配；作者/年份与正文对照。

正式来源页面

[P03] Chang Kong; Feng Li; Xiaohu Yan; Jinfeng Yang; Peng Mo; Qiuming Luo; Rui Mao. Object detection on low-compute edge SoCs: a reproducible benchmark and deployment guidelines. Scientific Reports, 2026.

DOI: 10.1038/s41598-026-36862-y；本地正文：论文\03_Rockchip多平台基准_2026\正文.pdf。

元数据核验：Crossref返回标题匹配；作者/年份与正文对照。

正式来源页面

[P04] Gongfan Fang; Xinyin Ma; Mingli Song; Michael Bi Mi; Xinchao Wang. DepGraph: Towards Any Structural Pruning. CVPR, 2023.

会议正式页面见HTML原文链接；本地正文：论文\04_DepGraph_CVPR2023\正文.pdf。

元数据核验：以本地正式会议PDF首页为准；P06另对照PMLR官方页面。

正式来源页面

[P05] Zhendong Yang; Zhe Li; Xiaohu Jiang; Yuan Gong; Zehuan Yuan; Danpei Zhao; Chun Yuan. Focal and Global Knowledge Distillation for Detectors. CVPR, 2022.

会议正式页面见HTML原文链接；本地正文：论文\05_FGD_CVPR2022\正文.pdf。

元数据核验：以本地正式会议PDF首页为准；P06另对照PMLR官方页面。

正式来源页面

引用说明：数字与机制解释以用户提供的正文为主要来源；原文页/表指向见各论文页。Crossref只验证书目信息，不认证论文方法与数值正确。

正文标题、作者与年份为主；12篇期刊DOI已在线匹配Crossref标题

参考文献与原文入口 6–10

[P06] Markus Nagel; Rana Ali Amjad; Mart van Baalen; Christos Louizos; Tijmen Blankevoort. Up or Down? Adaptive Rounding for Post-Training Quantization. ICML / PMLR 119, 2020.

会议正式页面见HTML原文链接；本地正文：论文\06_AdaRound_ICML2020\正文.pdf。

元数据核验：以本地正式会议PDF首页为准；P06另对照PMLR官方页面。

正式来源页面

[P07] Zishuo Wang; Tao Ding; Shuning Liang; Hongwei Cui; Xingquan Gao. Workpiece surface defect detection based on YOLOv11 and edge computing. PLOS One, 2025.

DOI: 10.1371/journal.pone.0327546；本地正文：论文\07_YOLO11_RK3568_2025\正文.pdf。

元数据核验：Crossref返回标题匹配；作者/年份与正文对照。

正式来源页面

[P08] Zhijun Rong; Aohan Deng; Yiheng Wang; Bingbing Dan; Liping Du; Chun Zhou. YOLO-RMF: A Real-Time Surface Defect Detection Model for Hot-Rolled Strip Steel with Reparameterized Convolution and Axial Attention. Sensors, 2026.

DOI: 10.3390/s26206533；本地正文：论文\08_YOLO_RMF_2026\正文.pdf。

元数据核验：Crossref返回标题匹配；作者/年份与正文对照。

正式来源页面

[P09] Qinyuan Huang; Ying Zhou; Tian Yang; Kun Yang; Lijia Cao; Yan Xia. A Lightweight Transfer Learning Model with Pruned and Distilled YOLOv5s to Identify Arc Magnet Surface Defects. Applied Sciences, 2023.

DOI: 10.3390/app13042078；本地正文：论文\09_弧形磁瓦_剪枝蒸馏_2023\正文.pdf。

元数据核验：Crossref返回标题匹配；作者/年份与正文对照。

正式来源页面

[P10] Shulong Zhuo; Xiaojian Zhou; Jiajing Cai; Hao Bai; Xu Duan; YiQun Ma. A lightweight network for phone surface defect detection with industrial deployment on RK3568 edge devices. PLOS One, 2025.

DOI: 10.1371/journal.pone.0336971；本地正文：论文\10_LNB_YOLO_RK3568_2025\正文.pdf。

元数据核验：Crossref返回标题匹配；作者/年份与正文对照。

正式来源页面

引用说明：数字与机制解释以用户提供的正文为主要来源；原文页/表指向见各论文页。Crossref只验证书目信息，不认证论文方法与数值正确。

正文标题、作者与年份为主；12篇期刊DOI已在线匹配Crossref标题

参考文献与原文入口 11–15

[P11] Yiqing Cao; Yonger Yao; Lijun Lu. Lightweight metal surface defect detection algorithm based on pruning and knowledge distillation. Scientific Reports, 2026.

DOI: 10.1038/s41598-026-57496-0；本地正文：论文\11_BFCD_KD_2026\正文.pdf。

元数据核验：Crossref返回标题匹配；作者/年份与正文对照。

正式来源页面

[P12] Zhenling Wang; Ya Gao; Ying Xiao; Qiurui He. A Lightweight and High-Precision PCB Surface Defect Detection Method Based on YOLOv8. Journal of Imaging, 2026.

DOI: 10.3390/jimaging12060266；本地正文：论文\12_PCB_YOLOv8_TensorRT_2026\正文.pdf。

元数据核验：Crossref返回标题匹配；作者/年份与正文对照。

正式来源页面

[P13] Gengliang Liang; Shijia Yu; Shuguang Han. RT-DETR-FFD: A Knowledge Distillation-Enhanced Lightweight Model for Printed Fabric Defect Detection. Electronics, 2025.

DOI: 10.3390/electronics14142789；本地正文：论文\13_RT_DETR_FFD_2025\正文.pdf。

元数据核验：Crossref返回标题匹配；作者/年份与正文对照。

正式来源页面

[P14] Yifei Ge; Zhuo Li; Lin Meng. YOLO-MSD: a robust industrial surface defect detection model via multi-scale feature fusion. Applied Intelligence, 2025.

DOI: 10.1007/s10489-025-06739-0；本地正文：论文\14_YOLO_MSD_2025\正文.pdf。

元数据核验：Crossref返回标题匹配；作者/年份与正文对照。

正式来源页面

[P15] Guiheng Zhang; Shuxian Liu; Shuaiqi Nie; Libo Yun. YOLO-RDP: Lightweight Steel Defect Detection through Improved YOLOv7-Tiny and Model Pruning. Symmetry, 2024.

DOI: 10.3390/sym16040458；本地正文：论文\15_YOLO_RDP_2024\正文.pdf。

元数据核验：Crossref返回标题匹配；作者/年份与正文对照。

正式来源页面

引用说明：数字与机制解释以用户提供的正文为主要来源；原文页/表指向见各论文页。Crossref只验证书目信息，不认证论文方法与数值正确。

使用记录 | 技能流程服务于学习结果，未虚构缺失脚本的运行

本次具体用了哪些skills

技能	本次实际应用	可见产物
literature-review	逐篇提取，再按剪枝/KD/量化/部署主题综合	15篇解读、知识地图与证据矩阵
scientific-critical-thinking	检查控制变量、数据划分、指标与外推	逐篇限制，P07/P10核验案例
pdf	页码化提取，回看关键原页，中文排版与渲染核验	PDF、原文摘图与页/表定位
nature-ref-verifier	DOI解析、标题/作者/年份字段对照	12条Crossref记录；3篇会议PDF核对
backward-traceability	借用来源/派生计算双向溯源原则，适配为PDF页表与结构化数据	图表原始CSV、计算式JSON；非LaTeX代码回链
algorithm-design	明确剪枝输入输出、依赖传播与阶段步骤	通道依赖图、通用教学算法
experiment-design	从跑通基线到假设、消融的四阶段设计	两/三数据来源路线、实验矩阵
scientific-visualization	仅同文同条件作数值图，标原点/缺失/变换	4张数据图、原始数值与完整图注
scientific-writing	先结构化笔记，再写问题—方法—证据—意义	统一解读、简明术语与事实/建议边界
scientific-schematics + imagegen	使用示意图设计原则；图像通过内置生成工具制作并人工核标签	训练/部署概念图，不充当实验结果

说明：本地部分技能仅含SKILL.md而无所引脚本，因此本次实际使用其工作流，并以现有工具完成提取、核验、制图与渲染；没有声称执行不存在的脚本。纯学习报告采用PDF技能的中文ReportLab排版，未套投稿论文的LaTeX模板。

方法工具引用 [S1] Timothy Kassis, Vinayak Agarwal, Yuhuan He, Darshil Patel, Aubrey M. Brueckner. Scientific Agent Skills: A Library of Procedural Knowledge for Research Agents. arXiv:2609.00065, 2026（2026-10-25核对官方记录，当前v2；引用不固定版本后缀）。https://doi.org/10.48550/arXiv.2609.00065。此为工具来源，不计入15篇工业研究。

方便复查，也避免把阅读分析误当成复现实验

范围、核验与交付说明

资料范围：指定文件夹15篇正文，共265个PDF页面；逐篇核读摘要、核心方法、实验与结论，对关键结果表、异常公式和脚注回看原页。使用已有阅读卡片/证据库作导航，并重新核读关键来源。非逐字翻译，也没有逐条验证每篇的参考文献。AdaRound官方补充材料用于确认附件与方法背景，不另计一篇。

书目核验：12篇期刊DOI通过Crossref返回标题匹配，保留作者、日期、卷期/文章号数据并与正文核对；三篇会议以本地正式PDF为主要记录，PMLR页面补核AdaRound。CVF与部分出版社页面本次访问受限，未把失败访问标成独立通过。DOI中出现更早年份不自动意味着出版年份错误。

统计边界：未做跨论文mAP/FPS排名或元分析；不把单次均值推断为显著提升；未报告的方差、功率、引擎mAP与板端延迟均保留为未知。文中回算值只验证算术一致性，不替作者重建完整测试协议。

实证边界：本报告未训练这些模型、未下载执行作者仓库代码、未连接你的相机或RK3568；推荐实验是可供执行的方案。关于你方向的建议结合此前工业视觉/RK3568背景，最终任务、产线约束和硬件配置仍应以你的实际项目为准。

文件/资料	用途
15篇工业缺陷检测论文_学习报告.pdf	完整可检索的中文顺序阅读与批注版
15篇工业缺陷检测论文_交互学习报告.html	自包含离线学习版：主题筛选、搜索、阅读进度与自测
图表与核验/图表原始数值.csv	每个数值图的配置、单位与原文位置
图表与核验/派生计算与来源.json	回算公式、结果、单位及适用解释
图表与核验/Crossref文献核验.json	原始书目查询字段与匹配状态
图表与核验/逐篇解读与来源.json	与报告一致的结构化阅读笔记

HTML的图表均内嵌，不依赖网络；点击本地原文需要保持此报告目录与上一层“论文”目录的位置关系。网页阅读进度保存在浏览器本地，隐私模式或禁用本地存储时不会持久保存。